



FOREST FIRE PREDICTION



INTRODUCERE



Proiectul se concentrează pe detectarea incendiilor de pădure folosind tehnici de inteligență artificială, cu scopul de a preveni și gestiona mai eficient dezastrele naturale.

Prin analiza automată a imaginilor satelitare, sistemul clasifică scenele în categorii relevante (foc / fără foc), oferind o alternativă modernă la metodele tradiționale.

👉 **Utilizarea AI** permite:

Detectare rapidă și precisă a incendiilor

Reducerea timpului de reacție

Minimizarea impactului asupra mediului și comunităților

LITERATURA



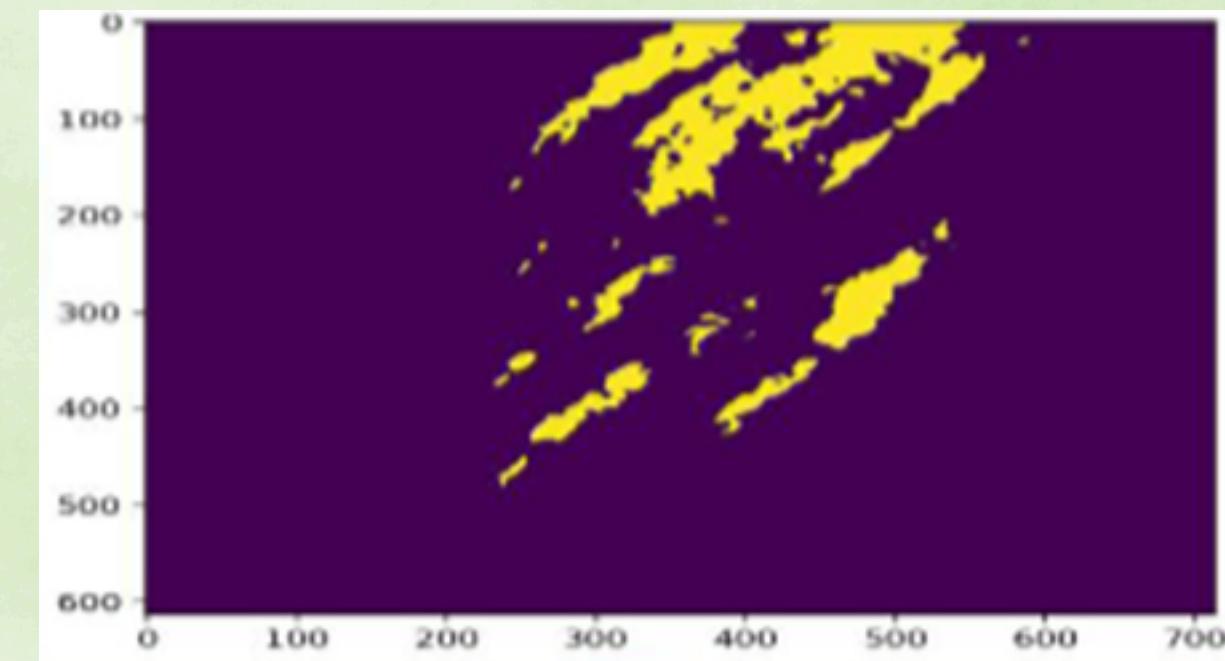
A. FOREST FIRE PREDICTION USING IMAGE PROCESSING AND MACHINE LEARNING

Setul de date este compus din imagini din satelit cu paduri (luate cu ajutorul API-ului de la Google). Datele folosite nu sunt disponibile.

Pentru a izola mult mai bine zona cu foc din imagine s-a schimbat imaginea din RGB in YCbCr (Luma ChrominanceBlue ChrominanceRed). Acest lucru ajuta si la a distinge mai bine zonele cu foc fata de zonele naturale sau zonele in care se reflecta soarele si reduce alarma falsa.

Se foloseste un model **R-CNN**

- Acuratete 92%
- Recall 97%
- F1-score 90%



LITERATURA



B. DEEP LEARNING APPROACHES FOR FOREST FIRES DETECTION AND PREDICTION USING SATELLITE IMAGES

Landsat-8 (NASA) contine imagini din satelit din America de Nord, Australia, Africa Centrala, Chernobyl si padurea Amazoniana.

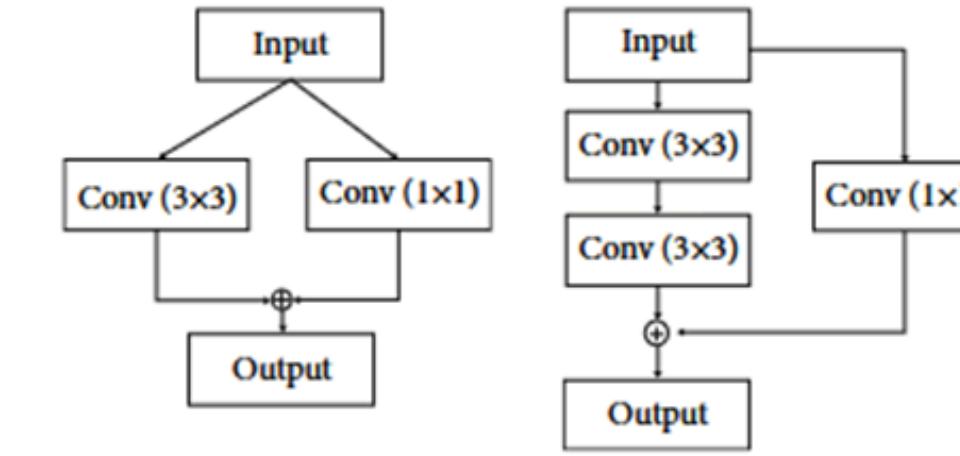
Se folosete un model numit FireNet

Optimizer: Adam: 0.001

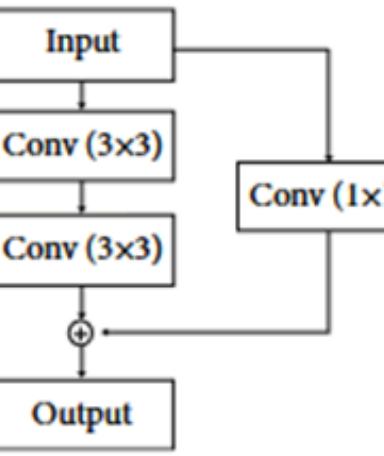
Batch: 7 patches

Epoci: 250

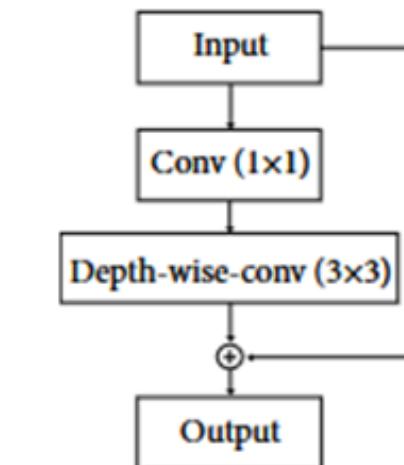
- Overall Accuracy (OA): 99.95% (Australia), 99.99% (Central Africa, Brazil, Chernobyl).
- Precision: 97.94% (Australia), 84.06% (Central Africa), 95.98% (Brazil), 95.98% (Chernobyl).
- Recall: 97.20% (Australia), 77.27% (Central Africa), 98.04% (Brazil), 98.04% (Chernobyl).
- F1-Score: 97.57% (Australia), 80.52% (Central Africa), 97.00% (Brazil), 97.24% (Chernobyl).



(a) Shallow Deep Feature Extractor



(b) Residual Block



(c) Residual Point/Depth-Wise Block

SET DE DATE



S-au folosit 5 seturi de date de pe kaggle care au fost curatare, iar fisierele corupte au fost eliminate.

Cateva exemple din seturile de date folosite:



CNN V1



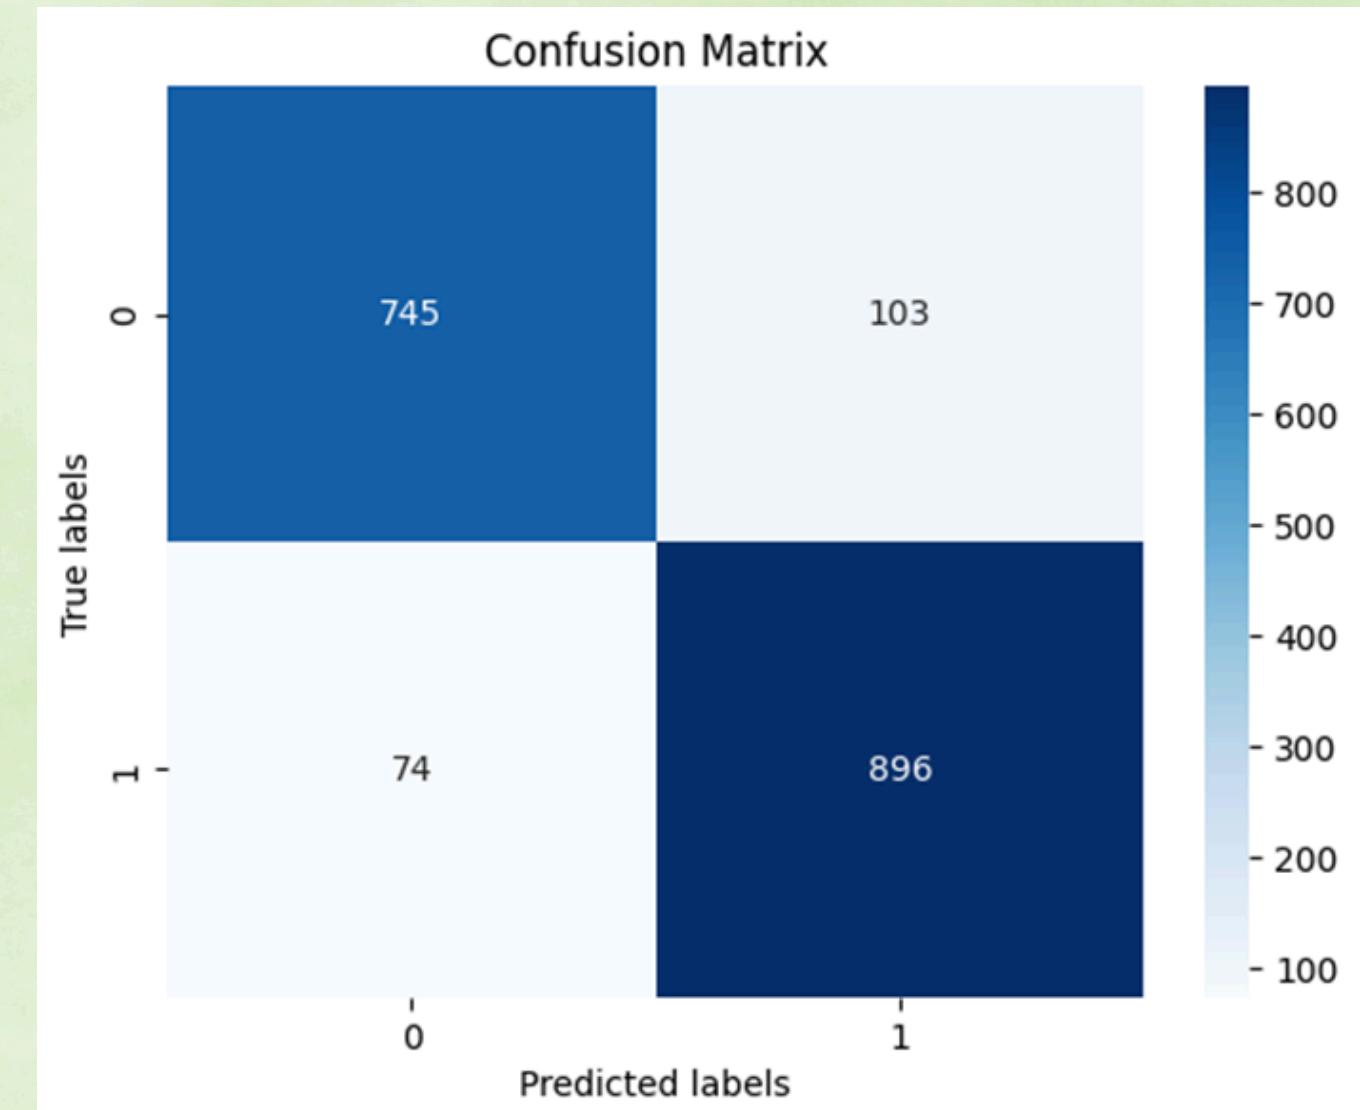
- 3 straturi Conv2D + MaxPooling – extrag și reduc caracteristici spațiale
- Număr de filtre: 32 → 64 → 128
- Flatten → transformare în vector
- Dense (128) + Dropout – prevenire overfitting
- Dense (1) cu activare sigmoid – clasificare finală

Model: "sequential"		
Layer (type)	Output Shape	Param #
conv2d (Conv2D)	(None, 254, 254, 32)	896
max_pooling2d (MaxPooling2D)	(None, 127, 127, 32)	0
conv2d_1 (Conv2D)	(None, 125, 125, 64)	18496
max_pooling2d_1 (MaxPooling2D)	(None, 62, 62, 64)	0
conv2d_2 (Conv2D)	(None, 60, 60, 128)	73856
max_pooling2d_2 (MaxPooling2D)	(None, 30, 30, 128)	0
flatten (Flatten)	(None, 115200)	0
dense (Dense)	(None, 128)	14745728
dropout (Dropout)	(None, 128)	0
dense_1 (Dense)	(None, 1)	129
Total params: 14,839,105		
Trainable params: 14,839,105		
Non-trainable params: 0		

REZULTATE V1



- RECALL: **92.47%**
- PRECISION: **89.69%**
- F1-SCORE: **91.06%**



CNN V2



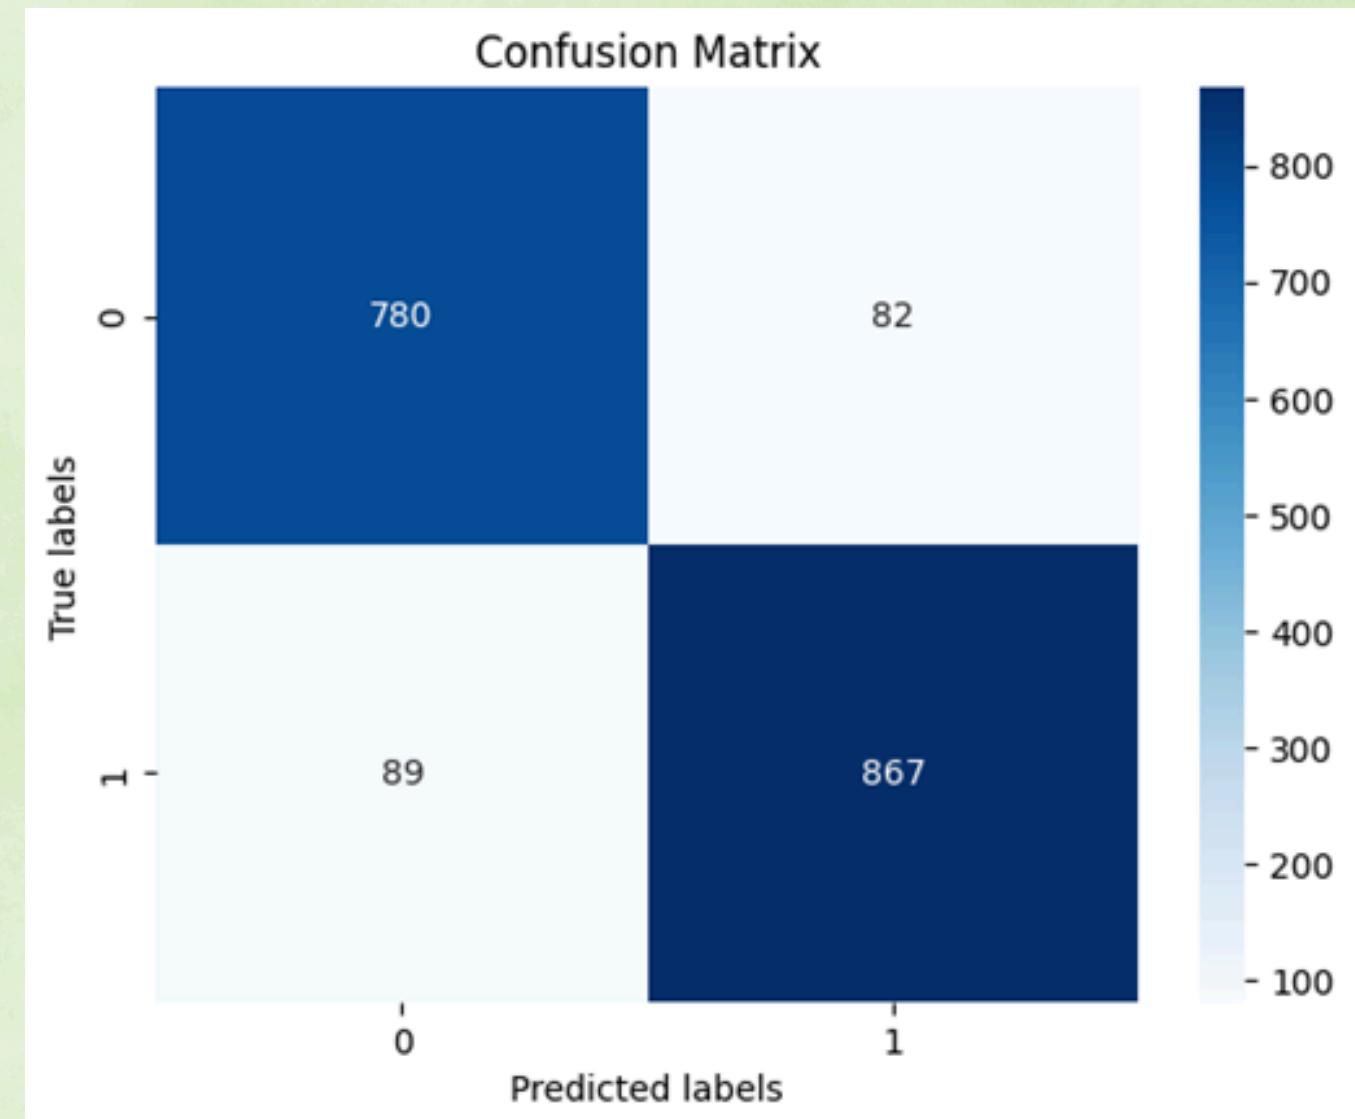
- Rescaling + BatchNormalization – stabilizare input
- 2 blocuri Conv2D (64) + MaxPooling + Dropout
- GlobalAveragePooling – reduce dimensiunea spațială fără Flatten
- 2 Dense layers (64, 1) + Dropout
- Optimizat pentru eficiență

Layer (type)	Output Shape	Param #
<hr/>		
rescaling_3 (Rescaling)	(None, 256, 256, 3)	0
conv2d_12 (Conv2D)	(None, 254, 254, 32)	896
batch_normalization_12 (BatchNormalization)	(None, 254, 254, 32)	128
conv2d_13 (Conv2D)	(None, 252, 252, 32)	9248
batch_normalization_13 (BatchNormalization)	(None, 252, 252, 32)	128
max_pooling2d_2 (MaxPooling2D)	(None, 126, 126, 32)	0
dropout_9 (Dropout)	(None, 126, 126, 32)	0
conv2d_14 (Conv2D)	(None, 124, 124, 64)	18496
batch_normalization_14 (BatchNormalization)	(None, 124, 124, 64)	256
conv2d_15 (Conv2D)	(None, 122, 122, 64)	36928
batch_normalization_15 (BatchNormalization)	(None, 122, 122, 64)	256
max_pooling2d_3 (MaxPooling2D)	(None, 61, 61, 64)	0
dropout_10 (Dropout)	(None, 61, 61, 64)	0
global_average_pooling2d_3 (GlobalAveragePooling2D)	(None, 64)	0
dense_6 (Dense)	(None, 64)	4160
dropout_11 (Dropout)	(None, 64)	0
dense_7 (Dense)	(None, 1)	65
<hr/>		
Total params:	70,561	
Trainable params:	70,177	
Non-trainable params:	384	

REZULTATE V2



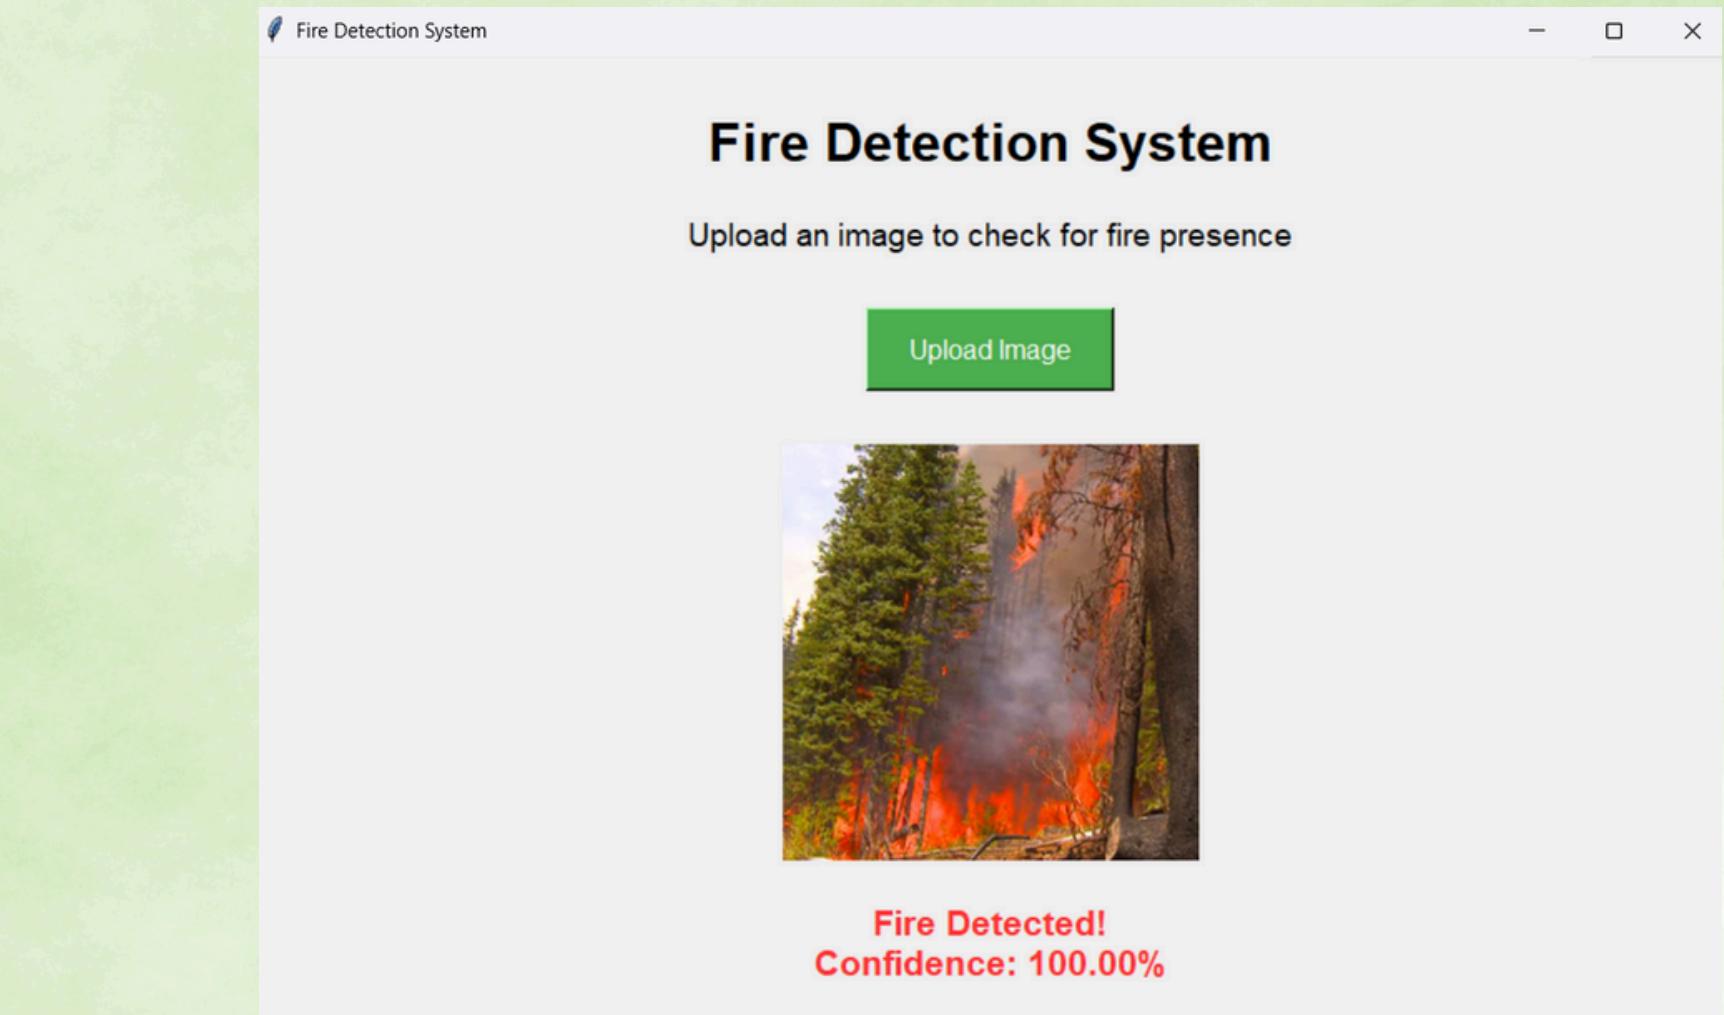
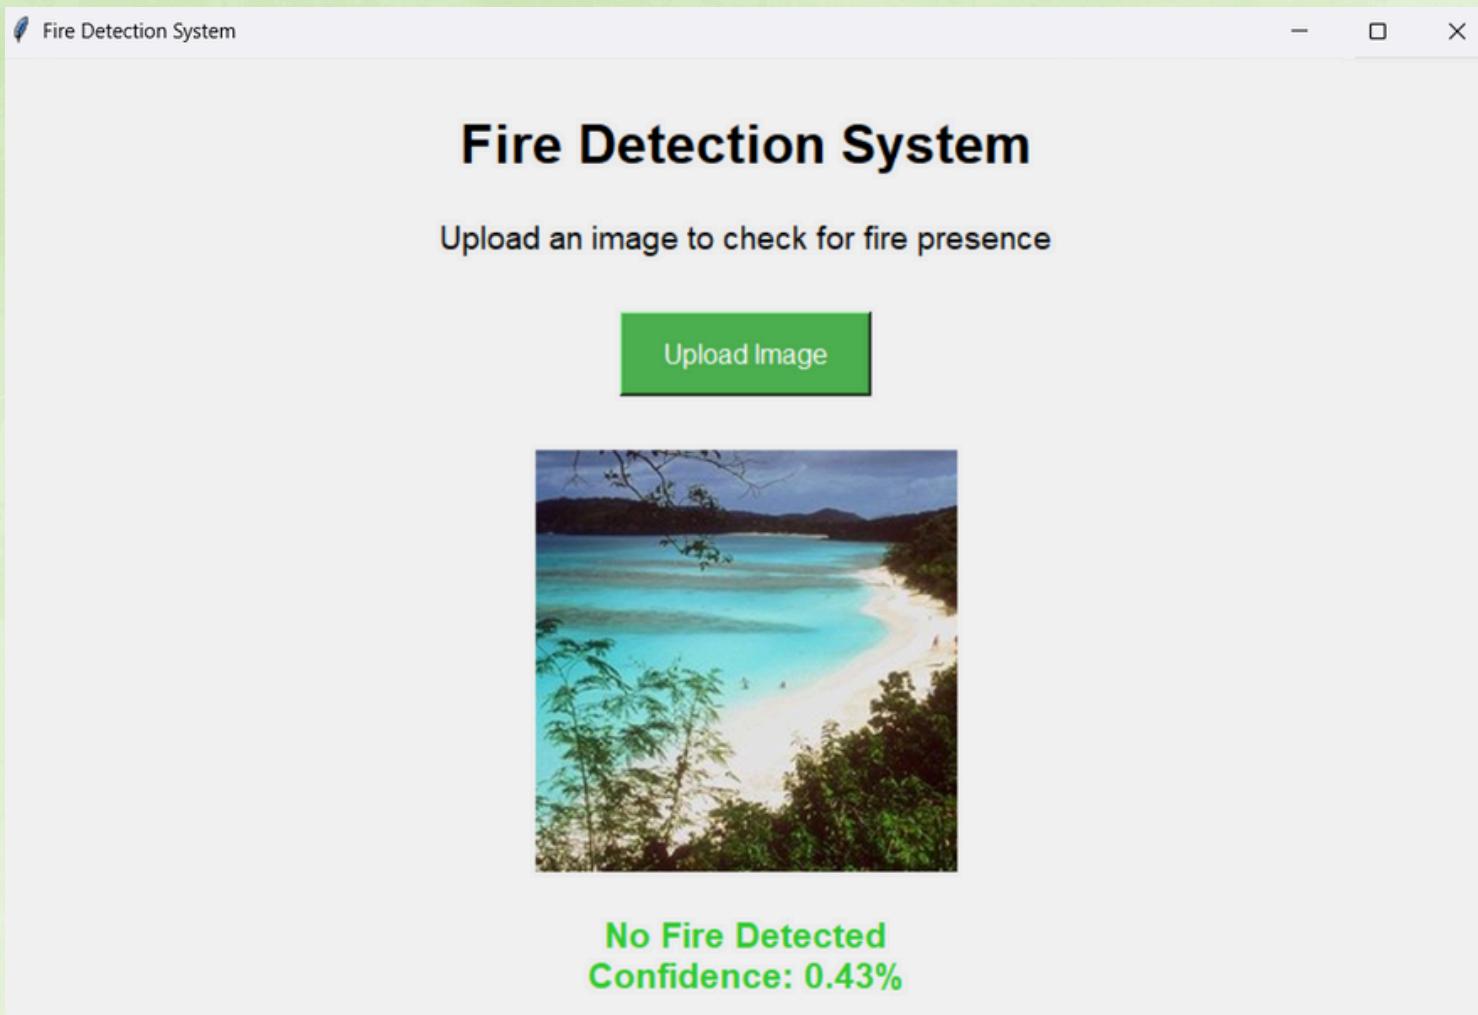
- **RECALL: 90.61%**
- **PRECISION: 91.36%**
- **F1-SCORE: 90.98%**



Fire Detection System

Upload an image to check for fire presence

Upload Image



CONCLUZII



🔥 Detectarea timpurie a incendiilor contribuie semnificativ la protejarea mediului înconjurător, prevenind răspândirea focului și reducând impactul asupra ecosistemelor și comunităților umane.

- Modelul 1 are un recall mai bun → detectează mai multe incendii
- Modelul 2 are o precizie mai mare → mai puține alarme false
- F1-score aproape identic → ambele modele sunt comparabile ca performanță
- Modelul 2 este preferat datorită eficienței și complexității reduse

FUTURE WORK



- Integrarea modelului cu sisteme de monitorizare în timp real (camere video, drone)
- Extinderea datasetului cu date din alte regiuni geografice
- Dezvoltarea unei aplicații mobile pentru alertare automată



THANK YOU

